PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMUN– SEDE TEMUCO

Análisis de datos de desembarque pesquero y acuícola en Chile

Grupo	:	N°9 AQUASAFE
Integrantes	:	Denise Ñancucheo Fedra Gotschlich
Asignatura	:	Programación Avanzada
Docente	:	Alex Flores Fuentealba
Ling GitHub:	:	https://github.com/Fessita/Proyecto_Pesquero_Acuicola
Fecha	:	27/10/2026
Nota	:	

INFORME Nº1

Descripción del problema

La pesca y la acuicultura son actividades importantes para Chile, debido a su participacion en la economia y al aprovechamiento de los recursos marinos. Analizar sus registros permite conocer cómo han variado las toneladas desembarcadas por especie a lo largo de los años, qué especies presentan mayores cambios y como se distribuyen estos resultados entre las distintas regiones del país. Sin embargo, debido a la gran cantidad de informacion disponible, puede llegar a ser dificil identificar las variaciones sin el uso de herramientas de analisis de datos. Además, para obtener resultados confiables es necesario revisar la calidad de los registros e identificar posibles errores, valores faltantes e inconsistencias.

El proyecto AQUASAFE, utiliza el archivo BD_desembarque.csv, obtenido del Anuario Estadístico de Pesca y Acuicultura de SERNAPESCA. El conjunto contiene información histórica sobre desembarques, incluyendo año, región, puerto, especie, toneladas y tipo de agente. La inspección inicial identificó 228.722 registros, 11 columnas y siete valores faltantes en la variable region.

Pregunta principal: ¿Qué especies y regiones presentan mayores variaciones en las toneladas de desembarque registradas en Chile durante el período analizado?

Objetivo general: Analizar la evolución histórica de los desembarques en Chile mediante Python y Pandas, para identificar qué especies presentan mayores aumentos o disminuciones en las toneladas registradas y comparar su comportamiento entre regiones.

Objetivos específicos:

1. Examinar la estructura, los tipos de datos, los valores faltantes y los duplicados.
2. Identificar inconsistencias y proponer tratamientos justificados.
3. Preparar los datos para comparar las toneladas por año, especie y región.

Los principales usuarios potenciales son estudiantes, docentes y personas interesadas en el análisis de información pesquera y acuícola. Los resultados pueden facilitar la identificación de tendencias en los desembarques registrados. No obstante, sus variaciones no demuestran por sí solas cambios en la abundancia biológica de las especies.

Fuente de datos

La fuente seleccionada corresponde al portal del Anuario Estadístico de Pesca y Acuicultura, específicamente a la sección de desembarque total.

Característica	Descripción
Nombre del archivo	BD_desembarque.csv
Fuente consultada	Anuario Estadístico de Pesca y Acuicultura
Organismo	Servicio Nacional de Pesca y Acuicultura (SERNAPESCA)
Enlace	https://anuario.sernapesca.dataobservatory.net/desembarque/total
Fecha de consulta	25 de octubre de 2026
Formato analizado	CSV
Dimensiones observadas	228.722 filas y 11 columnas
Período observado en el archivo	2000-2025
Licencia de uso	Pendiente de verificar en las condiciones de la fuente
Limitaciones iniciales	7 valores nulos en la columna región y posibles diferencias en categorías de texto

El archivo local utilizado para el análisis se encuentra en la carpeta datos/ del proyecto. Las dimensiones, el período y las características indicadas corresponden a la inspección del archivo descargado, no a una comprobación independiente de todos los registros publicados en el portal.

La selección de esta fuente se relaciona con el objetivo del proyecto, debido a que contiene variables que permiten estudiar los registros de toneladas por año, especie, región y tipo de agente. Antes de publicar conclusiones definitivas, se deberá conservar la información de procedencia de la descarga y verificar las definiciones, unidades y condiciones de uso disponibles en la fuente.

Diccionario de datos

El siguiente diccionario describe las once columnas encontradas durante la inspección inicial. Los tipos corresponden a los observados en Pandas; las descripciones se deben

contrastar con la documentación oficial cuando se confirme el significado específico de cada código.

Variable	Tipo observado	Descripción
id	Entero	Identificador del registro.
año	Entero	Año al que corresponde el registro.
aguas	Texto	Código o categoría relacionada con las aguas.
región	Texto	Región asociada al registro.
cd_puerto	Entero	Código del puerto de desembarque.
puerto_desembarque	Texto	Nombre del puerto de desembarque.
mes	Entero	Mes al que corresponde el registro.
cd_especie	Entero	Código de la especie.
especie	Texto	Nombre de la especie o recurso registrado.
toneladas	Entero	Cantidad registrada en la variable de toneladas; la unidad y su definición deben contrastarse con los metadatos.
tipo_agente	Texto	Categoría del agente o subsector indicada en el archivo.

La columna region presenta siete valores faltantes. En la inspección inicial no se encontraron valores nulos en las otras diez columnas. Las categorías de texto, especialmente aguas, deberán revisarse para comprobar si representan valores diferentes o si existen diferencias de escritura.

Diseño del pipeline de datos

El pipeline representa las etapas necesarias para transformar el archivo original en información preparada para el análisis.

Flujo de procesamiento:

Fuente de datos → Descarga del archivo → Almacenamiento en datos/ → Carga con Pandas → Inspección y validación → Limpieza y transformación → Análisis descriptivo → Visualización → Interpretación → Informe de resultados.

Etapa	Entrada	Proceso y herramienta	Salida
Obtención	Portal de SERNAPESCA	Descarga del archivo	Archivo CSV
Almacenamiento	Archivo descargado	Guardado en la carpeta datos/	Archivo local
Carga	CSV	pandas.read_csv()	DataFrame
Inspección	DataFrame	shape, dtypes, head(), isna(), duplicated() y describe()	Resumen inicial
Validación	Datos cargados	Revisión de tipos, rangos y categorías	Problemas identificados
Limpieza	Datos validados	Tratamiento documentado de faltantes e inconsistencias	Datos preparados
Análisis	Datos preparados	Agrupaciones y cálculos con Pandas	Indicadores por período, especie y región
Visualización	Indicadores	Gráficos, por ejemplo, con Matplotlib	Representaciones visuales
Interpretación	Tablas y gráficos	Análisis de resultados y limitaciones	Conclusiones
Informe	Evidencias y resultados	Redacción y exportación a PDF	Informe del proyecto

En el avance actual se implementaron la carga del archivo y la inspección inicial. La limpieza completa, las visualizaciones y el análisis ampliado corresponden a las siguientes etapas del proyecto.

Se eligió Pandas porque permite cargar archivos tabulares, consultar tipos de datos, contar valores faltantes y agrupar información mediante operaciones adecuadas para el procesamiento de datos. La separación entre carga e inspección facilita mantener el código organizado y reutilizable.

Implementación de la carga inicial con Pandas

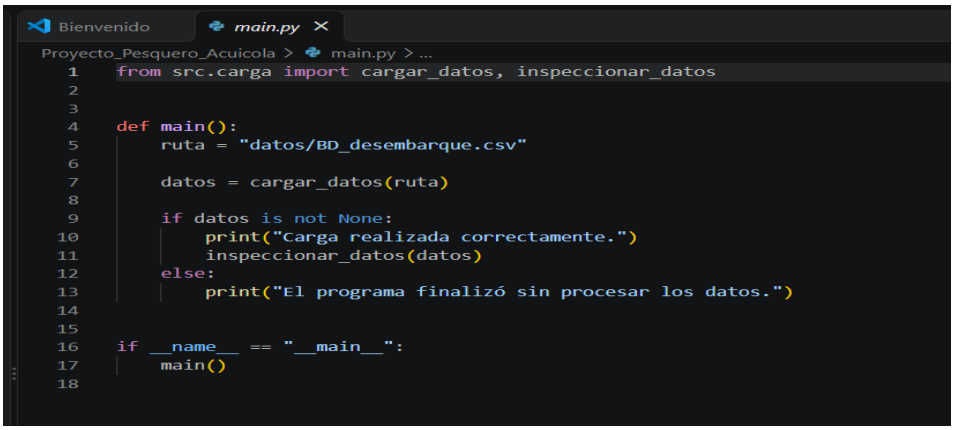
La función de carga se encuentra en src/carga.py. Utiliza pandas.read_csv() para leer el archivo, especificando el separador y la codificación utilizados por el CSV. Además, contempla excepciones para informar errores relacionados con la ubicación del archivo, su contenido, el formato o la codificación.





La función inspeccionar_datos() revisa las dimensiones del DataFrame, los nombres y tipos de las columnas, los primeros registros, los valores nulos, las filas duplicadas y el resumen estadístico. Estas operaciones permiten conocer la estructura de los datos antes de modificarlos.

El archivo main.py importa las funciones del módulo src.carga, define la ruta del CSV, ejecuta la carga y llama a la inspección solo cuando los datos se cargan correctamente. Esta organización separa las tareas y facilita el mantenimiento del programa.



Resultados de la inspección inicial

La ejecución del programa permitió cargar correctamente el archivo BD_desembarque.csv y obtener los siguientes resultados:

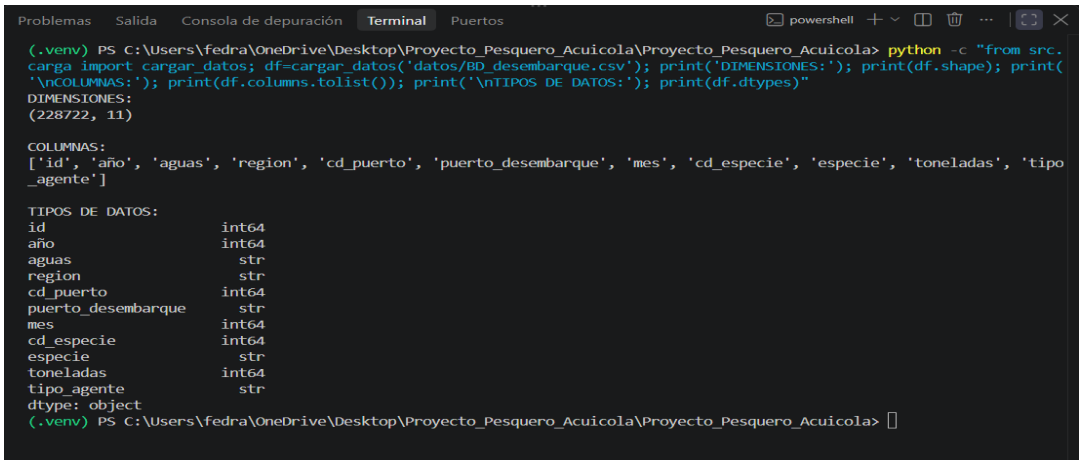
Indicador	Resultado
Número de filas	228.722

Número de columnas	11
Período observado	2000–2025
Columnas con valores nulos	1
Valores nulos en region	7
Filas completamente duplicadas	0
Categorías de especies observadas	276
Categorías observadas en aguas	3

Las once columnas fueron reconocidas con tipos enteros o de texto. Las variables id, año, cd_puerto, mes, cd_especie y toneladas fueron identificadas como enteras. Las variables aguas, region, puerto_desembarque, especie y tipo_agente fueron reconocidas como texto.

El resumen estadístico de toneladas mostró un mínimo de 1, una mediana de 9, una media aproximada de 487,61 y un máximo de 155.868. La diferencia entre la media y la mediana sugiere una distribución asimétrica, con algunos registros de valores elevados. Estos resultados deben interpretarse considerando las características y la unidad de la variable.

La revisión de categorías también mostró diferencias entre NAC y Nac. Aunque podrían representar una misma categoría escrita de distintas maneras, no deben unificarse hasta comprobar su significado. Asimismo, la ausencia de filas completamente duplicadas no descarta la existencia de registros repetidos según una combinación de variables de negocio.



Problemas detectados y tratamiento propuesto

La inspección inicial permitió identificar aspectos que deben revisarse antes de realizar análisis definitivos.

Problema	Evidencia	Tratamiento propuesto
Valores faltantes	7 nulos en region	Investigar su origen; recuperar el dato si existe una fuente confiable o documentar los faltantes.
Categorías diferentes	NAC y Nac en aguas	Contrastar los códigos con la documentación oficial antes de normalizarlos.
Categorías por validar	Valores de tipo_agente como Artesanal, Industrial y Acuicultura	Verificar las definiciones oficiales y el alcance de cada categoría.
Rangos temporales	Variables año y mes	Comprobar los años esperados y que los meses estén entre 1 y 12.
Valores extremos	Máximo de 155.868 en toneladas	Revisar los registros de mayor magnitud y confirmar su unidad, sin eliminarlos automáticamente.
Identificadores	El máximo de id es 238.051, mientras hay 228.722 filas	Investigar la secuencia y el origen de los identificadores; no asumir que deben ser consecutivos.
Posibles duplicados lógicos	No existen filas completamente duplicadas	Revisar combinaciones de año, mes, puerto, especie y tipo de agente para detectar posibles repeticiones.

Los valores faltantes no deben reemplazarse automáticamente por cero, porque se modificaría el significado de los datos. De la misma manera, los registros extremos no deben eliminarse solo por ser elevados: primero es necesario comprobar si corresponden a observaciones válidas.

Toda transformación deberá quedar documentada, indicando qué variable se modificó, qué regla se aplicó y por qué se consideró apropiada. Si no existe evidencia suficiente para corregir un dato, es preferible mantenerlo identificado y explicar la limitación.

Conclusión

La inspección inicial del archivo BD_desembarque.csv permitió comprobar que contiene 228.722 registros, 11 columnas y datos correspondientes al período 2000–2025. La información es útil para analizar las toneladas de desembarque por año, especie y región.

Se identificaron siete valores faltantes en región y diferencias de escritura en algunas categorías de aguas. Aunque no se encontraron filas completamente duplicadas, es necesario revisar posibles inconsistencias, validar las unidades y comprobar los registros extremos antes de realizar análisis definitivos.

La fuente es pertinente para comenzar el análisis, pero se debe confirmar la procedencia exacta del archivo y sus condiciones de uso. Como siguiente paso, se propone validar y limpiar los datos, documentar las modificaciones y elaborar tablas y gráficos para comparar los desembarques. Finalmente, las variaciones observadas deben interpretarse con precaución, ya que las toneladas registradas no representan por sí solas la abundancia biológica de las especies.

Reflexión metacognitiva

1. ¿Qué criterio utilizaron para seleccionar el problema?

Se consideró la relación de la fuente con el tema del proyecto y la disponibilidad de variables como año, región, especie y toneladas, necesarias para realizar comparaciones descriptivas.

2. ¿Por qué la fuente elegida es adecuada?

Porque SERNAPESCA es una institución oficial que proporciona datos históricos relacionados con nuestro proyecto. Además, el archivo contiene variables como año, región, especie y toneladas, necesarias para realizar el análisis.

3. ¿Qué variable podría generar mayores dificultades durante la limpieza?

La variable region, porque encontramos siete valores faltantes. Antes de corregirlos, debemos revisar por qué falta esa información y determinar cómo tratarla.

4. ¿Qué supuestos están realizando sobre los datos?

Suponemos inicialmente que los registros utilizan las mismas unidades de medida y que las categorías mantienen un significado consistente a lo largo de los años. Sin embargo, tendremos que comprobarlo durante la validación.

5. ¿Qué decisión del pipeline fue más difícil?

Definir cómo realizaremos la limpieza de los datos, especialmente el tratamiento de los valores faltantes y las diferencias de escritura, sin modificar incorrectamente la información original.

6. ¿Qué aprendieron al realizar la primera carga con Pandas?

Aprendimos a cargar un archivo CSV con Python y Pandas, revisar sus dimensiones, identificar los tipos de datos y detectar valores faltantes y registros duplicados.

7. ¿Qué error apareció durante la implementación?

Al principio tuvimos un problema con la codificación del archivo CSV, que impedía cargarlo correctamente. También apareció un error de indentación en el código.

8. ¿Cómo resolvieron ese error?

Modificamos la lectura del archivo utilizando el separador ; y la codificación latin-1. Después corregimos la indentación y ejecutamos nuevamente el programa hasta comprobar que funcionaba.

9. ¿Cómo distribuyeron las tareas dentro del equipo?

Denise se encargó principalmente de organizar los archivos del proyecto, programar y probar la carga e inspección de los datos. Fedra trabajó principalmente en la elaboración y organización del informe, incluyendo las tablas y las evidencias. Ambas participamos en la preparación y presentación del avance.

10. ¿Qué evidencia demuestra que el proyecto puede continuar?

Logramos cargar correctamente el archivo con 228.722 registros y 11 columnas, además de realizar la inspección inicial con Pandas. También diseñamos el pipeline que establece las etapas que seguiremos durante el resto del proyecto.

11. Referencias

Servicio Nacional de Pesca y Acuicultura. (s. f.). *Anuario Estadístico de Pesca y Acuicultura: Desembarque total*. https://anuario.sernapesca.dataobservatory.net/desembarque/total

pandas development team. (s. f.). *pandas documentation*. https://pandas.pydata.org/docs/

Python Software Foundation. (s. f.). *Python documentation*. https://docs.python.org/3/