PROGRAMACIÓN AVANZADA
ING. CIVIL PLAN COMUN– SEDE TEMUCO

Análisis de datos de desembarque pesquero y acuícola en Chile

Grupo	:	N°9 AQUASAFE
Integrantes	:	Denise Ñancucheo Fedra Gotschlich
Asignatura	:	Programación Avanzada
Docente	:	Alex Flores Fuentealba
Ling GitHub:	:	https://github.com/Fessita/Proyecto_Pesquero_Acuicola
Fecha	:	02/10/2026
Nota	:	

INFORME Nº2

Descripción del problema

La pesca y la acuicultura son actividades importantes para Chile, debido a su participacion en la economia y al aprovechamiento de los recursos marinos. Analizar sus registros permite conocer cómo han variado las toneladas desembarcadas por especie a lo largo de los años, qué especies presentan mayores cambios y como se distribuyen estos resultados entre las distintas regiones del país. Sin embargo, debido a la gran cantidad de informacion disponible, puede llegar a ser dificil identificar las variaciones sin el uso de herramientas de analisis de datos. Además, para obtener resultados confiables es necesario revisar la calidad de los registros e identificar posibles errores, valores faltantes e inconsistencias.

El proyecto AQUASAFE, utiliza el archivo BD_desembarque.csv, obtenido del Anuario Estadístico de Pesca y Acuicultura de SERNAPESCA. El conjunto contiene información histórica sobre desembarques, incluyendo año, región, puerto, especie, toneladas y tipo de agente. La inspección inicial identificó 228.722 registros, 11 columnas y siete valores faltantes en la variable region.

Pregunta principal: ¿Qué especies y regiones presentan mayores variaciones en las toneladas de desembarque registradas en Chile durante el período analizado?

Objetivo general: Analizar la evolución histórica de los desembarques en Chile mediante Python y Pandas, para identificar qué especies presentan mayores aumentos o disminuciones en las toneladas registradas y comparar su comportamiento entre regiones.

Objetivos específicos:

1. Examinar la estructura, los tipos de datos, los valores faltantes y los duplicados.
2. Identificar inconsistencias y proponer tratamientos justificados.
3. Preparar los datos para comparar las toneladas por año, especie y región.

Los principales usuarios potenciales son estudiantes, docentes y personas interesadas en el análisis de información pesquera y acuícola. Los resultados pueden facilitar la identificación de tendencias en los desembarques registrados. No obstante, sus variaciones no demuestran por sí solas cambios en la abundancia biológica de las especies.

Fuente de datos

La fuente seleccionada corresponde al portal del Anuario Estadístico de Pesca y Acuicultura, específicamente a la sección de desembarque total.

Característica	Descripción
Nombre del archivo	BD_desembarque.csv
Fuente consultada	Anuario Estadístico de Pesca y Acuicultura
Organismo	Servicio Nacional de Pesca y Acuicultura (SERNAPESCA)
Enlace	https://anuario.sernapesca.dataobservatory.net/desembarque/total
Fecha de consulta	25 de octubre de 2026
Formato analizado	CSV
Dimensiones observadas	228.722 filas y 11 columnas
Período observado en el archivo	2000–2025
Licencia de uso	Pendiente de verificar en las condiciones de la fuente
Limitaciones iniciales	7 valores nulos en la columna región y posibles diferencias en categorías de texto

El archivo original utilizado para el análisis se conserva en la carpeta datos/originales/, mientras que el conjunto de datos procesado se almacena en datos/procesados/dataset_limpio.csv. Esta organización permite mantener separados los datos originales y los resultados del procesamiento.

Las dimensiones, el período y las características indicadas corresponden a la inspección del archivo descargado, no a una comprobación independiente de todos los registros publicados en el portal.

La selección de esta fuente se relaciona con el objetivo del proyecto, debido a que contiene variables que permiten estudiar los registros de toneladas por año, especie, región y tipo de agente. Antes de publicar conclusiones definitivas, se deberá conservar la información de procedencia de la descarga y verificar las definiciones, unidades y condiciones de uso disponibles en la fuente.

Diccionario de datos

El diccionario de datos actualizado contiene 14 variables: 11 provenientes del archivo original y 3 incorporadas durante el segundo avance del proyecto AQUASAFE.

Las nuevas variables periodo, region_analisis y periodo_estudio permiten preparar la información para análisis temporales y regionales.

El conjunto procesado conserva los 228.722 registros originales. Asimismo, mantiene 7 valores nulos en la columna region, debido a su correspondencia con puertos extranjeros, según las validaciones realizadas.

Los tipos de datos indicados corresponden a los resultados obtenidos mediante Pandas. Las definiciones específicas de los códigos y categorías deberán contrastarse con la documentación oficial de la fuente.

Variable	Tipo de dato	Descripción
id	Entero	Identificador único del registro.
año	Entero	Año correspondiente al desembarque registrado.
aguas	Texto	Categoría de aguas asociada al desembarque.
region	Texto	Región asociada al registro; contiene 7 valores nulos.
cd_puerto	Entero	Código del puerto de desembarque.
puerto_desembarque	Texto	Nombre del puerto donde se registra el desembarque.
mes	Entero	Mes correspondiente al registro, expresado numéricamente.
cd_especie	Entero	Código identificador de la especie o recurso.
especie	Texto	Nombre de la especie o recurso registrado.
toneladas	Entero	Cantidad de toneladas registrada para el desembarque.

tipo_agente	Texto	Categoría del agente asociado al registro, como Artesanal, Industrial o Acuicultura.
periodo	Fecha	Nueva variable creada a partir del año y mes para facilitar el análisis temporal.
region_analisis	Texto	Nueva variable destinada a facilitar el análisis regional de los registros.
periodo_estudio	Booleano	Nueva variable que indica si un registro pertenece al período de estudio definido en el programa (True o False).

Diseño del pipeline de datos

El pipeline del proyecto AQUASAFE representa las etapas necesarias para cargar, revisar, limpiar, transformar y validar los registros de desembarque pesquero utilizando Python y Pandas.

Durante el segundo avance se implementaron las etapas de procesamiento y se generó un conjunto de datos preparado para los análisis posteriores.

Flujo de procesamiento:

Fuente de datos → Descarga del CSV → Almacenamiento del archivo original → Carga con Pandas → Diagnóstico inicial → Limpieza de datos → Tratamiento de nulos → Transformaciones → Validaciones finales → Exportación del CSV procesado.

Etapa	**Entrada**	**Proceso y herramienta**	**Salida**
Obtención	Portal de SERNAPESCA	Descarga del archivo	BD_desembarque.csv
Almacenamiento	Archivo descargado	Conservación del CSV original	Archivo en datos/originales/

Carga	Archivo CSV original	pandas.read_csv()	DataFrame de 228.722 filas y 11 columnas
Inspección	DataFrame original	shape, dtypes, head(), isna(), duplicated() y describe()	Diagnóstico inicial
Limpieza	Datos inspeccionados	Normalización de categorías y limpieza de espacios	Datos estandarizados
Tratamiento de nulos	Datos con 7 nulos en region	Evaluación y conservación justificada	Registros conservados
Transformaciones	Datos limpios	Creación de periodo, region_analisis y periodo_estudio	DataFrame de 14 columnas
Validación final	Datos transformados	Revisión de columnas, tipos, rangos e identificadores	Datos validados
Exportación	DataFrame procesado	Exportación a CSV con Pandas	datos/procesados/dataset_limpio.csv
Análisis	Datos procesados	Agrupaciones y cálculos con Pandas	Indicadores por año, especie y región
Visualización	Indicadores	Elaboración de gráficos, por ejemplo, con Matplotlib	Representaciones visuales
Interpretación	Tablas y gráficos	Análisis de resultados y limitaciones	Conclusiones

Informe	Evidencias y resultados	Redacción y exportación a PDF	avance_2.pdf

Durante el segundo avance del proyecto AQUASAFE se implementaron las etapas de carga, inspección, limpieza, tratamiento de valores nulos, transformaciones, validación y exportación de datos mediante Python y Pandas.

El conjunto original contiene 228.722 registros y 11 columnas. Después del procesamiento, se conservaron los registros originales y se incorporaron tres nuevas variables, obteniendo un conjunto de 14 columnas.

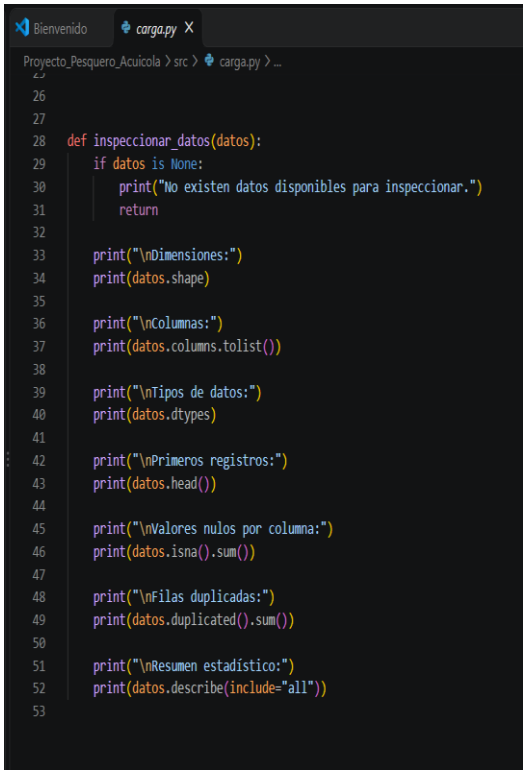
El programa se organizó en módulos para facilitar su mantenimiento y permitir la ejecución automática de las distintas etapas del pipeline.

El análisis descriptivo ampliado, las visualizaciones y la interpretación de tendencias corresponden a las siguientes etapas del proyecto.

Implementación de la carga inicial con Pandas

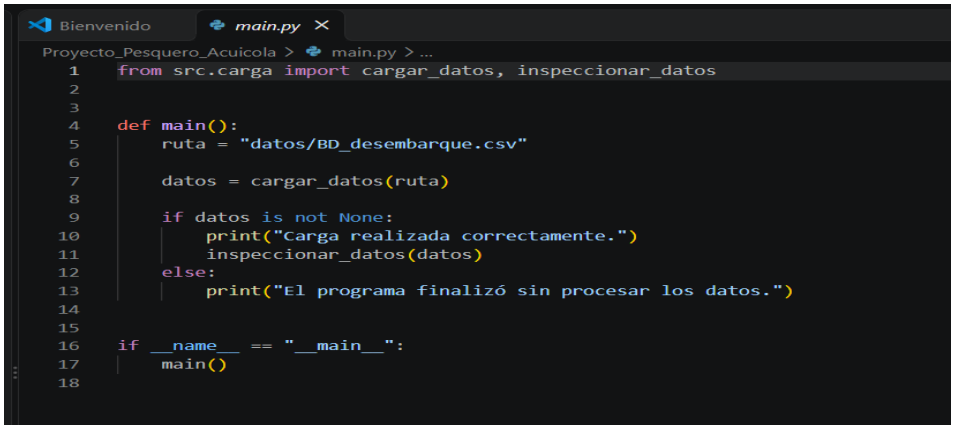
La función de carga se encuentra en src/carga.py. Utiliza pandas.read_csv() para leer el archivo, especificando el separador y la codificación utilizados por el CSV. Además, contempla excepciones para informar errores relacionados con la ubicación del archivo, su contenido, el formato o la codificación.





La función inspeccionar_datos() revisa las dimensiones del DataFrame, los nombres y tipos de las columnas, los primeros registros, los valores nulos, las filas duplicadas y el resumen estadístico. Estas operaciones permiten conocer la estructura de los datos antes de modificarlos.

El archivo main.py importa las funciones del módulo src.carga, define la ruta del CSV, ejecuta la carga y llama a la inspección solo cuando los datos se cargan correctamente. Esta organización separa las tareas y facilita el mantenimiento del programa.



Resultados de la inspección inicial

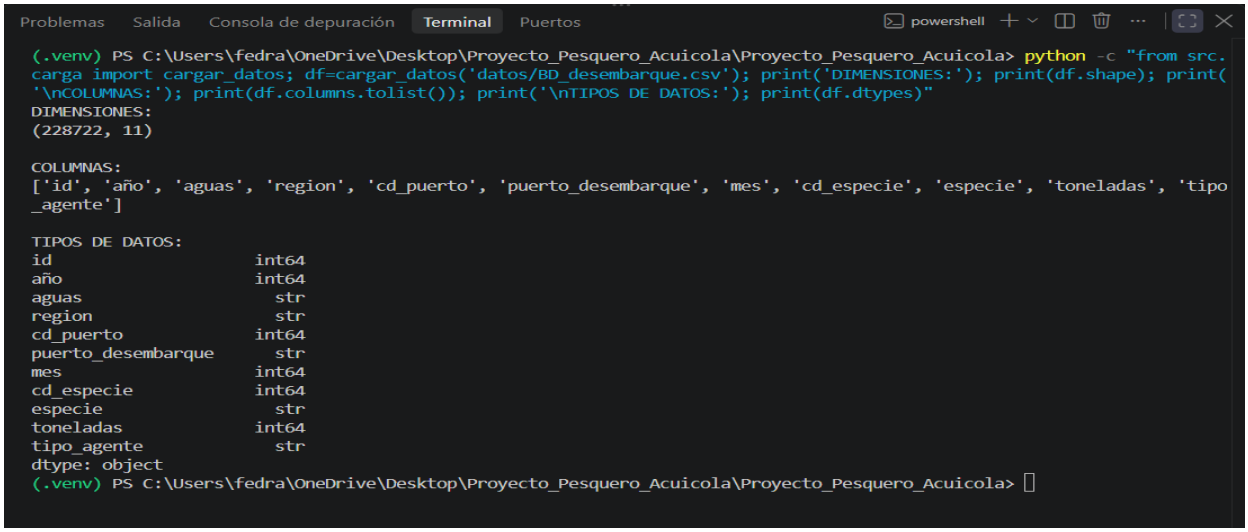
La ejecución del programa permitió cargar correctamente el archivo BD_desembarque.csv y obtener los siguientes resultados:

Indicador	Resultado
Número de filas	228.722
Número de columnas	11
Período observado	2000–2025
Columnas con valores nulos	1
Valores nulos en region	7
Filas completamente duplicadas	0
Categorías de especies observadas	276
Categorías observadas en aguas	3

Las once columnas fueron reconocidas con tipos enteros o de texto. Las variables id, año, cd_puerto, mes, cd_especie y toneladas fueron identificadas como enteras. Las variables aguas, region, puerto_desembarque, especie y tipo_agente fueron reconocidas como texto.

El resumen estadístico de toneladas mostró un mínimo de 1, una mediana de 9, una media aproximada de 487,61 y un máximo de 155.868. La diferencia entre la media y la mediana sugiere una distribución asimétrica, con algunos registros de valores elevados. Estos resultados deben interpretarse considerando las características y la unidad de la variable.

La revisión de categorías también mostró diferencias entre NAC y Nac. Aunque podrían representar una misma categoría escrita de distintas maneras, no deben unificarse hasta comprobar su significado. Asimismo, la ausencia de filas completamente duplicadas no descarta la existencia de registros repetidos según una combinación de variables de negocio.



Problemas detectados y tratamiento propuesto

La inspección inicial permitió identificar aspectos que deben revisarse antes de realizar análisis definitivos.

Problema	Evidencia	Tratamiento propuesto
Valores faltantes	7 nulos en region	Investigar su origen; recuperar el dato si existe una fuente confiable o documentar los faltantes.
Categorías diferentes	NAC y Nac en aguas	Contrastar los códigos con la documentación oficial antes de normalizarlos.
Categorías por validar	Valores de tipo_agente como Artesanal, Industrial y Acuicultura	Verificar las definiciones oficiales y el alcance de cada categoría.
Rangos temporales	Variables año y mes	Comprobar los años esperados y que los meses estén entre 1 y 12.
Valores extremos	Máximo de 155.868 en toneladas	Revisar los registros de mayor magnitud y confirmar su unidad, sin eliminarlos automáticamente.
Identificadores	El máximo de id es 238.051, mientras hay 228.722 filas	Investigar la secuencia y el origen de los identificadores; no asumir que deben ser consecutivos.
Posibles duplicados lógicos	No existen filas completamente duplicadas	Revisar combinaciones de año, mes, puerto, especie y tipo de agente para detectar posibles repeticiones.

Los valores faltantes no deben reemplazarse automáticamente por cero, porque se modificaría el significado de los datos. De la misma manera, los registros extremos no deben eliminarse solo por ser elevados: primero es necesario comprobar si corresponden a observaciones válidas.

Toda transformación deberá quedar documentada, indicando qué variable se modificó, qué regla se aplicó y por qué se consideró apropiada. Si no existe evidencia suficiente para corregir un dato, es preferible mantenerlo identificado y explicar la limitación.

1. Diagnóstico inicial de calidad de datos

Para el segundo avance del proyecto AQUASAFE se realizó un diagnóstico de calidad del conjunto de datos de desembarque pesquero utilizando Python y la biblioteca Pandas.

El archivo original contiene **228.722 registros y 11 columnas**, con información correspondiente al período 2000–2025.

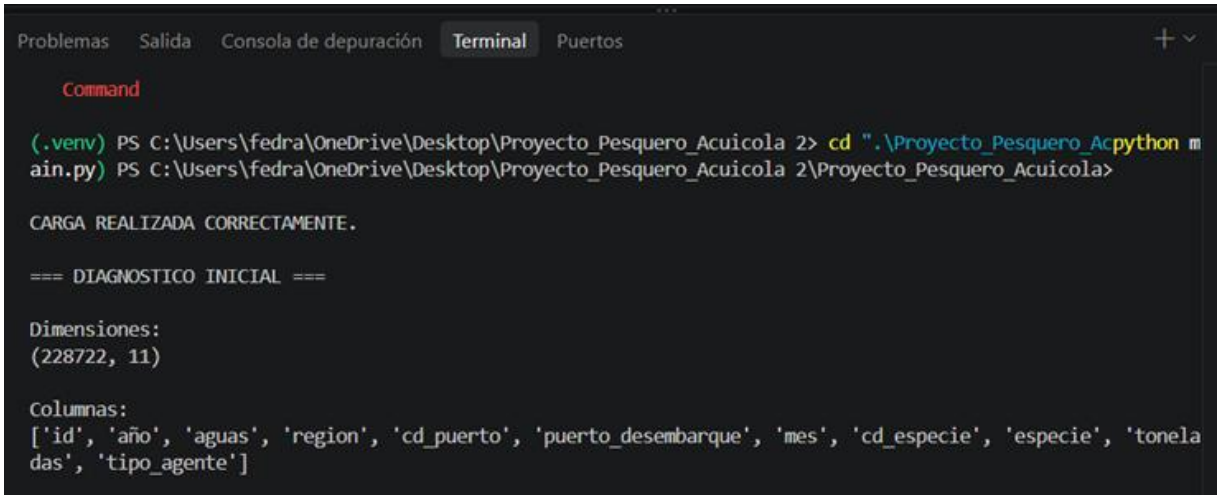
Se analizaron las dimensiones, los tipos de datos, los valores nulos, los registros duplicados y los posibles valores fuera de rango.

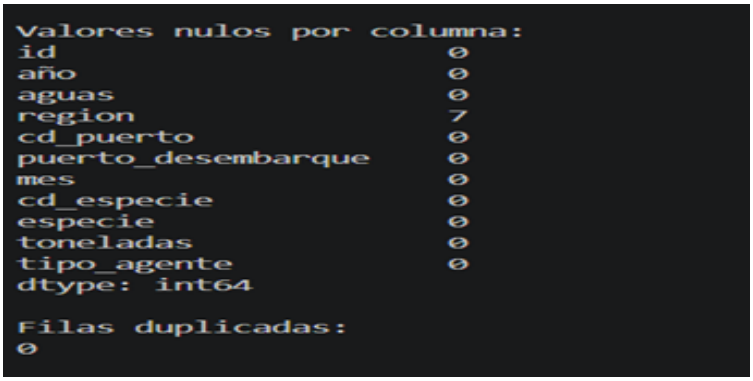
Los resultados muestran que existen **7 valores nulos en la columna region**, equivalentes aproximadamente al 0,0031 % de sus registros. No se encontraron filas completamente duplicadas ni identificadores repetidos.

Además, se verificó que no existen meses o años fuera de los rangos establecidos ni valores negativos en la columna toneladas.

También se identificó una inconsistencia en la escritura de la variable aguas, donde aparecen las categorías NAC y Nac, situación que se aborda durante la limpieza.

Este diagnóstico permitió identificar los problemas de calidad del conjunto original y establecer las acciones necesarias para su procesamiento.





2. Limpieza de datos

Después del diagnóstico inicial, se realizó un proceso de limpieza del conjunto de datos mediante Python y Pandas, con el objetivo de mejorar la consistencia de la información y facilitar los análisis posteriores.

Durante la revisión se identificó una inconsistencia en la variable aguas, debido a que la categoría nacional aparecía escrita de dos maneras: NAC y Nac.

Para corregir esta situación, se aplicó una normalización de las categorías, unificando ambas formas de escritura en NAC.

Además, se ejecutó una limpieza de espacios en las variables de texto para evitar diferencias provocadas por espacios innecesarios.

Resumen de las acciones de limpieza

Problema identificado	Acción realizada	Resultado
Categorías NAC y Nac	Unificación de escritura	Categoría normalizada
Posibles espacios innecesarios	Limpieza de espacios en textos	Textos estandarizados
Filas duplicadas	Verificación de duplicados	No se detectaron duplicados
Valores fuera de rango	Verificación de años, meses y toneladas	No se detectaron valores fuera de rango

El proceso permitió mejorar la consistencia de las categorías sin eliminar registros. El conjunto de datos conservó sus **228.722 filas originales**.

La limpieza constituye una etapa fundamental para evitar que diferencias de escritura produzcan agrupaciones incorrectas durante el análisis estadístico.

```
CATEGORIAS ORIGINALES DE AGUAS:
aguas
NAC     209761
Nac      16298
AI        2663
Name: count, dtype: int64

CATEGORIAS ORIGINALES DE TIPO DE AGENTE:
tipo_agente
Artesanal       178076
Industrial       26906
Acuicultura      23740
Name: count, dtype: int64

=== LIMPIEZA DE DATOS ===
Valores de texto corregidos: 2
Limpieza de espacios ejecutada.
```

3. Tratamiento de valores nulos

Durante el diagnóstico inicial del proyecto AQUASAFE se identificaron 7 valores nulos en la columna region, de un total de 228.722 registros.

Mediante las validaciones realizadas en Python, se comprobó que estos registros corresponden a puertos extranjeros, por lo que no tienen una región chilena asociada.

Por esta razón, se decidió conservar los valores nulos en lugar de reemplazarlos por información ficticia o eliminar los registros.

Tabla de tratamiento de valores nulos

Variable	Nulos iniciales	Estrategia aplicada	Justificación	Nulos finales

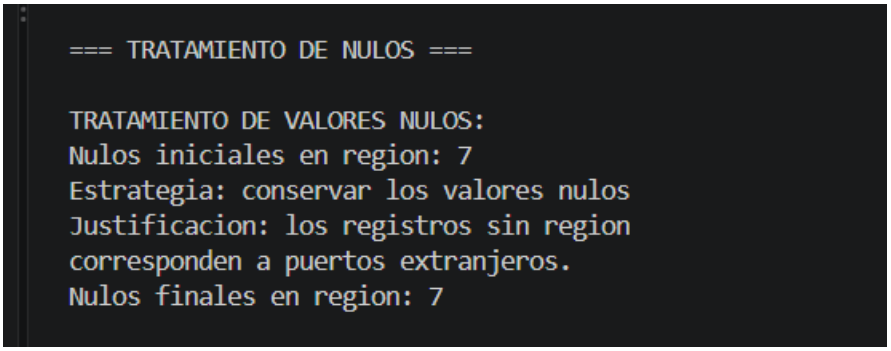
región	7	Conservar los valores nulos	Corresponden a puertos extranjeros sin región chilena asociada	7
Otras variables	0	No requieren tratamiento	No presentan valores nulos	0

Resultado del tratamiento

Después de aplicar la estrategia, el conjunto de datos mantiene los 7 valores nulos originales en la columna region.

Esta decisión permite conservar la información de desembarques asociados a puertos extranjeros y evita la eliminación innecesaria de registros válidos.

El proceso de tratamiento de valores nulos no modificó la cantidad total de filas del conjunto de datos.



4. Transformaciones de datos

Después de realizar la limpieza y el tratamiento de valores nulos, se aplicaron transformaciones mediante Python y Pandas para facilitar el análisis de los desembarques pesqueros del proyecto AQUASAFE.

Se incorporaron tres nuevas variables al conjunto de datos: periodo, region_analisis y periodo_estudio.

Tabla de transformaciones realizadas

Variables de origen	**Transformación**	**Variable resultante**	**Tipo de dato final**
año y mes	Construcción de una fecha a partir del año y mes de cada registro	periodo	datetime64[us]
región	Creación de una variable destinada al análisis regional	region_analisis	Texto (str)

Información temporal del registro	Clasificación según pertenencia al período de estudio	periodo_estudio	Booleano (bool)

Primera transformación: creación de la variable periodo.

Se combinaron los valores de año y mes para generar una fecha que representa el período de cada desembarque. Esta transformación facilita los análisis temporales.

Segunda transformación: creación de la variable region_analisis.

Se incorporó una columna destinada a facilitar la clasificación y el análisis de los desembarques según su ubicación regional.

Tercera transformación: creación de la variable periodo_estudio.

Se creó una variable booleana que identifica si cada registro pertenece al período de estudio definido en el programa.

La ejecución obtuvo los siguientes resultados:

- Registros clasificados como True: 93.816.
- Registros clasificados como False: 134.906.

Resultado final

El conjunto de datos pasó de **11 a 14 columnas**, manteniendo sus **228.722 registros originales**.

Las tres variables nuevas permiten organizar la información temporal y regional y preparar el conjunto de datos para los análisis posteriores.

```
=== TRANSFORMACIONES ===
Dimensiones: (228722, 14)

COLUMNAS NUEVAS:
     periodo region_analisis  periodo_estudio
0 2000-01-01        Tarapacá            False
1 2000-01-01        Tarapacá            False
2 2000-01-01        Tarapacá            False
3 2000-01-01        Tarapacá            False
4 2000-01-01        Tarapacá            False

REGISTROS SEGUN PERIODO DE ESTUDIO:
periodo_estudio
False    134906
True      93816
Name: count, dtype: int64
```

5. Modularización del código

Para el desarrollo del segundo avance de AQUASAFE, el programa se organizó mediante una estructura modular en Python.

Esta organización permite separar las tareas de carga, limpieza, transformación y validación de datos, facilitando la lectura, el mantenimiento y la reutilización del código.

Organización de los módulos

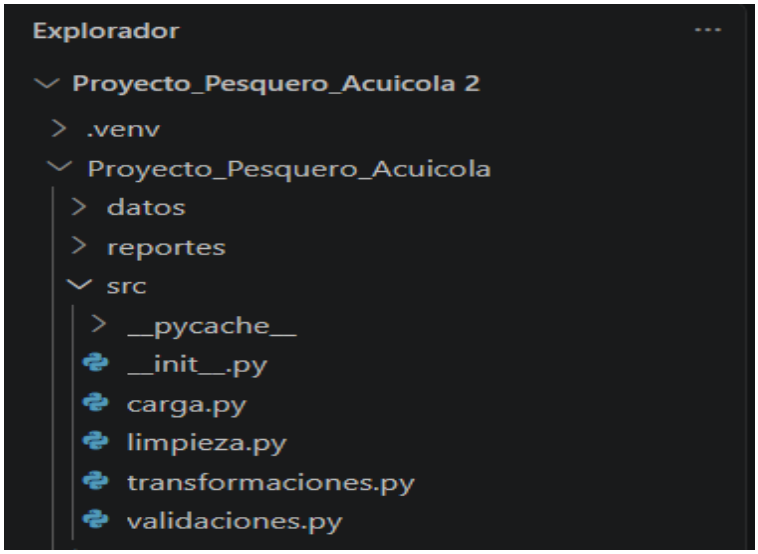
Archivo	Responsabilidad
main.py	Coordinar y ejecutar las etapas del procesamiento de datos.
src/carga.py	Cargar el conjunto de datos y realizar su inspección inicial.
src/limpieza.py	Aplicar procedimientos de limpieza y tratamiento de valores nulos.
src/transformaciones.py	Generar las nuevas variables utilizadas en el análisis.
src/validaciones.py	Verificar la calidad, consistencia y validez de los datos procesados.
src/__init__.py	Permitir la organización de los módulos dentro del paquete src.

Flujo de procesamiento

El programa sigue una secuencia de trabajo que comienza con la lectura del archivo original y continúa con el diagnóstico de calidad, la limpieza, el tratamiento de valores nulos, las transformaciones y las validaciones finales.

Una vez completadas estas etapas, el conjunto procesado se exporta al archivo datos/procesados/dataset_limpio.csv.

La modularización facilita la identificación de errores y permite modificar una etapa del procesamiento sin necesidad de reorganizar todo el programa.



6. Validaciones finales de calidad de datos

Después de aplicar los procesos de limpieza, tratamiento de valores nulos y transformaciones, se ejecutaron validaciones automáticas mediante Python y Pandas.

El objetivo fue comprobar que el conjunto de datos procesado mantuviera su integridad y cumpliera las condiciones necesarias para los análisis posteriores.

Resultados de las validaciones

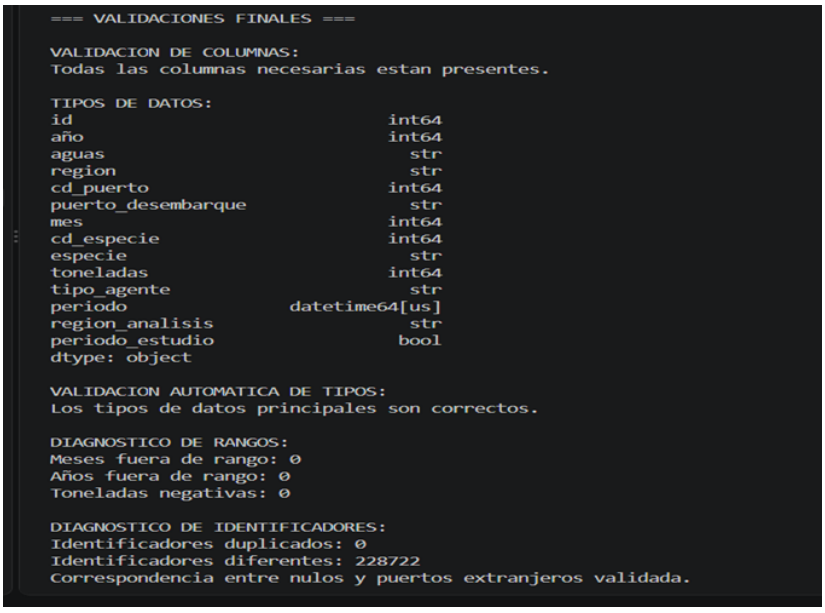
Validación realizada	**Resultado**
Presencia de columnas necesarias	Todas presentes
Tipos de datos principales	Correctos
Meses fuera de rango	0
Años fuera de rango	0
Toneladas negativas	0
Identificadores duplicados	0
Identificadores diferentes	228.722
Correspondencia de nulos con puertos extranjeros	Validada

Las comprobaciones confirmaron que no existen registros con meses o años fuera de los rangos definidos por el programa, ni cantidades negativas de toneladas.

También se verificó que los 228.722 identificadores son diferentes, por lo que no se detectaron identificadores repetidos.

Respecto de los 7 valores nulos de la variable region, el programa validó su correspondencia con puertos extranjeros, respaldando la decisión de conservarlos.

En consecuencia, las validaciones ejecutadas finalizaron correctamente y el conjunto procesado quedó preparado para las siguientes etapas de análisis.



```
=== VALIDACIONES FINALES ===

VALIDACION DE COLUMNAS:
Todas las columnas necesarias estan presentes.

TIPOS DE DATOS:
id                              int64
año                             int64
aguas                             str
region                            str
cd_puerto                       int64
puerto_desembarque                str
mes                             int64
cd_especie                      int64
especie                           str
toneladas                       int64
tipo_agente                       str
periodo               datetime64[us]
region_analisis                   str
periodo_estudio                  bool
dtype: object

VALIDACION AUTOMATICA DE TIPOS:
Los tipos de datos principales son correctos.

DIAGNOSTICO DE RANGOS:
Meses fuera de rango: 0
Años fuera de rango: 0
Toneladas negativas: 0

DIAGNOSTICO DE IDENTIFICADORES:
Identificadores duplicados: 0
Identificadores diferentes: 228722
Correspondencia entre nulos y puertos extranjeros validada.
```

7. Comparación antes y después del procesamiento

Para evaluar los resultados del procesamiento de datos del proyecto AQUASAFE, se realizó una comparación entre el conjunto original y el conjunto procesado.

Esta comparación permite identificar los cambios producidos durante las etapas de limpieza, tratamiento de valores nulos y transformaciones.

Tabla comparativa de resultados

Indicador	Antes	Después
Cantidad de filas	228.722	228.722
Cantidad de columnas	11	14
Valores nulos	7	7
Filas duplicadas	0	0
Valores fuera de rango	0	0
Variables con cambio de tipo	0	0
Variables nuevas	0	3

Análisis de los resultados

Los resultados muestran que el conjunto de datos mantuvo sus 228.722 registros originales, por lo que no fue necesario eliminar filas durante el procesamiento.

La cantidad de columnas aumentó de 11 a 14 debido a la incorporación de tres nuevas variables: periodo, region_analisis y periodo_estudio.

Los 7 valores nulos de la columna region se conservaron debido a que corresponden a registros de puertos extranjeros, según las validaciones realizadas.

No se encontraron filas duplicadas ni valores fuera de rango en las comprobaciones ejecutadas.

Además, se normalizaron categorías de texto y se ejecutó la limpieza de espacios para mejorar la consistencia de la información.

Exportación del conjunto procesado

Al finalizar el procesamiento, los datos se exportaron al archivo datos/procesados/dataset_limpio.csv.

Posteriormente, el programa verificó el archivo generado y confirmó que contiene 228.722 registros, 14 columnas, 7 valores nulos y ninguna fila completamente duplicada.

La ejecución finalizó correctamente, dejando disponible un conjunto de datos procesado para las siguientes etapas del proyecto AQUASAFE.

```
=== COMPARACION ANTES Y DESPUES ===
                    Indicador  Antes  Despues
                        Filas 228722   228722
                     Columnas     11       14
                Valores nulos      7        7
             Filas duplicadas      0        0
       Valores fuera de rango      0        0
Variables transformadas (tipo)      0        0
             Variables nuevas      0        3

=== EXPORTACION ===
Dataset procesado exportado: datos\procesados\dataset_limpio.csv

=== VERIFICACION DEL CSV ===
Dimensiones: (228722, 14)
Nulos: 7
Filas duplicadas: 0

PIPELINE AQUASAFE FINALIZADO CORRECTAMENTE.
```

Conclusión

Durante el segundo avance del proyecto AQUASAFE se desarrolló un proceso automatizado de limpieza, transformación y validación de datos utilizando Python y la biblioteca Pandas.

El conjunto original contenía 228.722 registros y 11 columnas. Mediante el diagnóstico inicial se identificaron 7 valores nulos en la variable region y diferencias de escritura en las categorías de la variable aguas.

Durante la limpieza se normalizaron las categorías y se ejecutó un procedimiento de estandarización de espacios en las variables de texto. Los valores nulos de region se conservaron debido a su correspondencia con puertos extranjeros, evitando la eliminación innecesaria de información.

También se incorporaron tres nuevas variables: periodo, region_analisis y periodo_estudio, aumentando la cantidad de columnas de 11 a 14.

Las validaciones finales confirmaron que no existen identificadores duplicados, toneladas negativas ni valores fuera de los rangos establecidos para años y meses.

Finalmente, se exportó el conjunto procesado al archivo datos/procesados/dataset_limpio.csv, conservando los 228.722 registros originales.

En conclusión, el segundo avance permitió mejorar la consistencia de los datos, organizar el código en módulos y establecer un proceso reproducible para preparar la información que será utilizada en las siguientes etapas de análisis pesquero y acuícola.

Reflexión metacognitiva

1. ¿Qué criterio utilizaron para seleccionar el problema?

Se consideró la relación de la fuente con el tema del proyecto y la disponibilidad de variables como año, región, especie y toneladas, necesarias para realizar comparaciones descriptivas.

2. ¿Por qué la fuente elegida es adecuada?

Porque SERNAPESCA es una institución oficial que proporciona datos históricos relacionados con nuestro proyecto. Además, el archivo contiene variables como año, región, especie y toneladas, necesarias para realizar el análisis.

3. ¿Qué variable podría generar mayores dificultades durante la limpieza?

La variable region, porque encontramos siete valores faltantes. Antes de corregirlos, debemos revisar por qué falta esa información y determinar cómo tratarla.

4. ¿Qué supuestos están realizando sobre los datos?

Suponemos inicialmente que los registros utilizan las mismas unidades de medida y que las categorías mantienen un significado consistente a lo largo de los años. Sin embargo, tendremos que comprobarlo durante la validación.

5. ¿Qué decisión del pipeline fue más difícil?

Definir cómo realizaremos la limpieza de los datos, especialmente el tratamiento de los valores faltantes y las diferencias de escritura, sin modificar incorrectamente la información original.

6. ¿Qué aprendieron al realizar la primera carga con Pandas?

Aprendimos a cargar un archivo CSV con Python y Pandas, revisar sus dimensiones, identificar los tipos de datos y detectar valores faltantes y registros duplicados.

7. ¿Qué error apareció durante la implementación?

Al principio tuvimos un problema con la codificación del archivo CSV, que impedía cargarlo correctamente. También apareció un error de indentación en el código.

8. ¿Cómo resolvieron ese error?

Modificamos la lectura del archivo utilizando el separador ; y la codificación latin-1. Después corregimos la indentación y ejecutamos nuevamente el programa hasta comprobar que funcionaba.

9. ¿Cómo distribuyeron las tareas dentro del equipo?

Denise se encargó principalmente de organizar los archivos del proyecto, programar y probar la carga e inspección de los datos. Fedra trabajó principalmente en la elaboración y organización del informe, incluyendo las tablas y las evidencias. Ambas participamos en la preparación y presentación del avance.

10. ¿Qué evidencia demuestra que el proyecto puede continuar?

Logramos cargar correctamente el archivo con 228.722 registros y 11 columnas, además de realizar la inspección inicial con Pandas. También diseñamos el pipeline que establece las etapas que seguiremos durante el resto del proyecto.

Referencias

Servicio Nacional de Pesca y Acuicultura. (s. f.). *Anuario Estadístico de Pesca y Acuicultura: Desembarque total*. https://anuario.sernapesca.dataobservatory.net/desembarque/total

pandas development team. (s. f.). *pandas documentation*. https://pandas.pydata.org/docs/

Python Software Foundation. (s. f.). *Python documentation*. https://docs.python.org/3/